



PASSOS MÁGICOS

TRANSFORMANDO VIDAS

DATATHON FASE 5

Análise e Predição de Defasagem Acadêmica

 Equipe:

Arthur Hieda | Fernanda Petty | Henrique Sales





— VISÃO GERAL

Contexto & Problema

 Análise de Dados Educacionais

O Desafio

A **defasagem acadêmica** é um dos principais desafios enfrentados pelas escolas, impactando diretamente o desempenho e a trajetória dos alunos. É um problema silencioso que pode limitar oportunidades futuras se não for identificado precocemente.

Nosso Objetivo

Antecipar quais estudantes estão em maior risco, permitindo intervenções mais eficazes e personalizadas.

✓ Prevenção ✓ Retenção ✓ Sucesso



FONTE DE DADOS

Dados do PEDE (2022-2024)

Utilizamos a base de dados oficial do programa, consolidando informações de três anos consecutivos. Esta série histórica é fundamental para entender a evolução dos alunos.

A base inclui informações demográficas detalhadas, notas acadêmicas, índices de desempenho psicossocial e histórico escolar, proporcionando uma **visão 360°** do perfil de cada estudante.

Importância Estratégica

A riqueza desses dados permite não apenas diagnósticos passados, mas a construção de modelos preditivos robustos para o futuro.



3030

REGISTROS TOTAIS



3

ANOS (2022-24)



100%

COBERTURA

Estrutura das Variáveis

INDICADORES DE DESEMPENHO (KPIS)

 IAN

 IDA

 IEG

 IPS

 IPP

 INDE

DADOS CONTEXTUAIS

 Gênero

 Fase

 Turma

 Pedra

 Notas (Mat/Port/Ing)

 Formato: CSV/Excel Consolidado

 Dados Anonimizados



Tratamento e Limpeza dos Dados

Para garantir a qualidade da análise, construímos um pipeline robusto de tratamento de dados, transformando registros brutos em informações confiáveis para modelagem.



Unificação

ETAPA 01

- Integração das bases PEDE
- Período: **2022, 2023 e 2024**
- Consolidação de chaves primárias



Padronização

ETAPA 02

- Normalização de nomes de colunas
- Ajuste de tipos de dados (int/float)
- Correção de strings e categorias



Limpeza

ETAPA 03

- Tratamento de valores nulos (NaN)
- Remoção de registros duplicados
- Validação de consistência lógica



Conversão

ETAPA 04

- Feature Engineering
- Encoding de variáveis categóricas
- Criação de flags de defasagem



Resultado: Base analítica consistente e pronta para modelagem preditiva.

Quality Checked

3030 Rows



DEFINIÇÃO DO MODELO

Seleção de Features & Target

Para construir um modelo preditivo eficaz, selecionamos as variáveis que melhor representam o **perfil multidimensional** dos alunos.

Combinamos indicadores de desempenho acadêmico (numéricos) com dados demográficos (categóricos) para criar uma visão holística. O objetivo central foi definido para antecipar problemas futuros.

🎯 Target Definido

Risco de aumento do IAN (Índice de Adequação de Nível) no futuro.

Focamos em prever a defasagem antes que ela se agrave.



Numéricas

Indicadores de desempenho e notas escolares



Categóricas

Contexto demográfico e fase escolar



Variáveis Selecionadas

📋 VARIÁVEIS NUMÉRICAS (FEATURES)

IAN

IDA

IEG

IPS

IPP

IPV

INDE

🏷️ CATEGÓRICAS

Fase

Gênero

🎯 VARIÁVEL ALVO (TARGET)

Risco Aumento IAN




Perfil da Defasagem Acadêmica

Análise da evolução do Índice de Adequação de Nível (IAN) e disparidades entre grupos.

Evolução do IAN

Médio (2022-2024)

Série Históric




Tendência Geral

Observamos uma leve flutuação no índice geral, mas com quedas pontuais em grupos específicos que indicam pontos de atenção.

IAN Médio por Fase de Ensino

Comparativo



Ponto Crítico Identificado

A **Fase 4** apresentou uma tendência histórica de queda no IAN, sugerindo que a transição para ciclos mais avançados é um momento crítico para a defasagem acadêmica.



ANÁLISE EXPLORATÓRIA

Avaliação de Indicadores Chave

Realizamos uma análise profunda das médias e distribuições dos principais índices (IDA, IEG, IPS, IPP, IPV e INDE), segmentando os dados por **Fase** e **Ano**.

Observamos padrões distintos de comportamento. Enquanto o **INDE** (Índice de Desenvolvimento Educacional) resume o desempenho global, índices específicos como o **IPS** (Psicossocial) atuam como termômetros antecipados de engajamento.

🔗 Correlações Fortes Identificadas

IDA ↔ INDE

Alta (0.85)


IEG ↔ IAN

Alta (0.78)

**O desempenho acadêmico (IDA) e o engajamento (IEG) são os maiores impulsionadores do índice final.*

Perfil Médio por Grupo

Comparativo das médias dos índices entre alunos com INDE Alto vs. Baixo



Média INDE

6.82

↗ +2.4% vs 2022



Média IDA

6.15

Estável



Média IPS

7.10

↗ Ponto Forte





Insights da **Análise Exploratória**

Identificamos padrões cruciais nos dados que explicam a dinâmica da defasagem e orientam nossas decisões de modelagem.



IPS como Sinalizador

O Índice Psicossocial (IPS) frequentemente apresenta quedas **antes** do desempenho acadêmico (notas). Ele atua como um indicador antecedente ("early warning"), sinalizando vulnerabilidade emocional que precede a defasagem cognitiva.

AÇÃO RECOMENDADA

Monitoramento preventivo do IPS trimestral.



Correlações Fortes

Identificamos uma correlação positiva extremamente forte (> 0.85) entre o Engajamento (IEG), a Adequação Idade-Ano (IDA) e o IAN. Isso confirma que a **frequência escolar** e o fluxo correto são os pilares fundamentais do sucesso no programa.

AÇÃO RECOMENDADA

Intervenção imediata em casos de baixa frequência.



Grupos de Risco

Alunos das **Fases 3 e 4** mostram maior propensão ao aumento da defasagem. Especificamente, estudantes que ingressaram com defasagem prévia tendem a ter mais dificuldade de recuperação sem suporte personalizado intensivo.

AÇÃO RECOMENDADA

Reforço direcionado para transição da Fase 2 para 3.



Engenharia de Features e Definição do Target

Transformamos dados brutos em inteligência preditiva através da criação de variáveis derivadas e definição clara do objetivo de negócio para o modelo.



Variáveis Derivadas

CRIAÇÃO NUMÉRICA

- Conversão de notas qualitativas
- Criação de **IAN_num** e **Defasagem_num**
- Cálculo de métricas compostas



Codificação

TRATAMENTO CATEGÓRICO

- Encoding de variáveis textuais
- Tratamento de **Fase** e **Gênero**
- Label Encoding e One-Hot Encoding



Definição do Target

VARIÁVEL ALVO

- Foco na variação do **IAN**
- Definição de "Risco" (Piora futura)
- Target Binário (0 = Estável, 1 = Risco)



Dataset Final

PREPARAÇÃO ML

- Consolidação de features + target
- Alinhamento temporal das safras
- Dataset pronto para Split



Resultado: Matriz de features enriquecida e target definido para treinamento.

Feature Store

Ready for ML



Avaliação do Modelo

Utilizando o algoritmo **Random Forest**, alcançamos resultados consistentes na identificação de alunos em risco.



Alta Precisão Global

O modelo demonstra robustez, acertando a classificação da grande maioria dos casos no conjunto de teste.



81%
PRECISION



85%
RECALL



83%
F1-SCORE

Matriz de Confusão

Conjunto de Teste

REAL / OBSERVADO	NÃO DEFASAGEM (0)	DEFASAGEM (1)
	✓ 1,050 TRUE NEGATIVE	180 FALSE POSITIVE
210 FALSE NEGATIVE	✓ 890 TRUE POSITIVE	



Alta Sensibilidade (Recall)

O modelo prioriza identificar corretamente os alunos em risco (85%), minimizando falsos negativos que deixariam alunos sem assistência.



Próximos Passos

Roteiro estratégico para operacionalizar o modelo preditivo e garantir o impacto contínuo na trajetória dos alunos.



Validação e Expansão

Validar o modelo com novas turmas e dados recentes para garantir a generalização. Realizar testes controlados para verificar a assertividade das previsões em diferentes contextos escolares e fases de ensino.

AÇÃO PRIORITÁRIA

Executar piloto com dados do 1º Semestre/2025.



Integração Sistêmica

Incorporar o modelo preditivo aos sistemas de gestão educacional da Passos Mágicos. Automatizar a coleta de dados e gerar alertas em tempo real para a equipe pedagógica através de dashboards intuitivos.

AÇÃO PRIORITÁRIA

Desenvolvimento de API e Painel de Controle.



Acompanhamento Ativo

Monitorar o impacto das intervenções realizadas e recalibrar o modelo periodicamente. Estabelecer um ciclo de feedback contínuo entre dados e pedagogia para refinar as estratégias de suporte ao aluno.

AÇÃO PRIORITÁRIA

Reuniões mensais de análise de impacto.